



本科生实验报告

实验课程：多模态大模型

作业名称：基于VLM的智能图文问答助手

专业名称：计算机科学与技术

报告时间：2026/6/18

学号	23336307	23336238
姓名	张若璇	王梓芸

目录

一、项目概述	3
二、相关工作与技术选型	4
三、系统设计与实现细节	5
3.1 系统整体架构	5
3.2 核心模块实现细节	6
3.3 代码仓库说明	9
四、实验设计与定量结果	10
4.1 实验设置	10
4.2 定量实验结果	10
4.3 可视化与错误分析	11
五、反思与展望	15
5.1 项目整体反思	15
5.2 AGI 视角下的技术瓶颈	15
5.3 未来改进方向	15
六、总结	16
6.1 项目完成情况	16
6.2 收获与体会	16
参考文献	17

一、项目概述

本项目聚焦多模态图文问答场景，基于大语言模型搭建一套完整的图像文本问答交互系统，核心实现图片与文本联合输入、智能问答、多轮上下文对话、可视化交互与多数据集性能评测等核心功能。结合项目开发需求与课程实验要求，对整体开发任务进行模块化拆解，并制定清晰、可落地的功能验收标准，明确系统开发目标与实验验证维度，具体任务拆解与对应验收标准如下：

1.1 项目核心任务拆解

1.模型加载与推理接口封装

- 本任务为系统核心基础模块，主要完成大模型接口的适配与二次封装。由于官方指定多模态模型Qwen2.5-VL存在接口权限与访问限制，本项目选用其他轻量化大模型作为替代，基于阿里云DashScope API完成模型远程调用配置。通过封装模型推理接口，统一实现图像接收、文本提问、模型推理、结果返回的标准化流程；

2. 多轮对话与图像预处理实现

- 针对项目核心的多轮上下文交互需求，本任务主要实现对话状态持久化与图像输入预处理功能。依托后台状态变量存储对话历史记录，完成用户提问与模型回复的上下文拼接与迭代更新，使系统具备记忆历史对话的能力，解决单轮问答无上下文、交互割裂的问题；

3. 多数据集评测与指标计算

- 为全面、客观验证系统与模型的实际性能，本任务完成多场景数据集选型、批量测试与定量指标统计，选用ChineseSimpleVQA、DuReader_vis两大公开中文VQA数据集，搭配自建文档、风景混合数据集，覆盖自然场景、文档文字、真实实拍三大核心场景。通过统计各数据集问答准确率，完成多维度定量数据统计，结合可视化图表直观展示模型性能差异，实现系统功能的量化评测，形成完整的实验数据支撑；

4. Web可视化交互界面实现

- 为降低用户操作门槛，实现无代码可视化交互，本任务基于Gradio框架搭建轻量化Web前端交互界面。替代传统命令行单调交互模式，实现图片上传、文本输入、多轮对话实时展示、对话记录保存等可视化功能，界面布局简洁直观、交互逻辑清晰，支持普通用户快速上手操作。

1.2 项目验收标准

1. 多轮图文问答功能验收标准。支持图片、文本联合输入的图文问答模式，可正常接收用户上传的各类场景图片与自定义提问，能够基于历史对话上下文完成多轮连续问答；

2. 可视化交互界面验收标准。成功搭建可用的Web可视化交互界面，替代传统命令行交互模式，界面功能完整、布局规范；

3. 多数据集评测指标验收标准。完成两大公开数据集与一套自建混合数据集的全量测试，覆盖自然场景、文档文字、真实实拍多类场景；
4. 典型案例分析验收标准。基于多数据集测试结果，筛选4组成功案例与4组失败案例，覆盖全部实验场景。结合案例实际表现完成定性分析，归纳模型与系统的优势、缺陷，完成错误类型归类总结，形成完整的实验案例分析内容，支撑项目反思与后续优化工作。

二、相关工作与技术选型

2.1 视觉语言模型（VLM）基础

- 主流架构分类：
1. 双编码器模型（CLIP系列）：图文特征对齐，适合检索类任务，推理能力弱

2. 融合式模型（BLIP/BLIP-2）：跨模态注意力融合，适合基础问答

3. 大语言模型增强型（LLaVA/Qwen-VL）：视觉编码器+投影层+LLM，对话与推理能力强，是当前主流
- 模型对比：
- 本项目在选型阶段调研了以下三款主流开源视觉语言模型：

对比维度	Qwen2.5-VL (7B)	LLaMA 3.2 Vision (11B)	Gemma 3-Vision (7B)
研发机构	阿里云	Meta	Google
中文支持	原生深度优化	多语言支持但中文较弱	以英文为主
文档理解	强（DocVQA 91.4%）	中	中
部署成本	1×24GB GPU	1×24GB+ GPU	1×16-24GB GPU
开源协议	Apache 2.0	LLaMA 社区许可	Gemma 许可

- 中文场景适配性分析：
- Qwen2.5-VL 在中英文图文理解方面具有显著优势。根据官方技术报告，Qwen-VL-Max 在中文问答和中文文本理解任务上超越 GPT-4V 和 Gemini Ultra。LLaMA 3.2 Vision 虽然支持多语言，但训练数据以英文为主，中文图文问答场景下准确率明显偏低。Gemma 3-Vision 同样以英文为核心，缺少针对中文场景的专项优化。

2.2 技术栈与选型理由

- 核心模型：
- 本系统选用阿里云通义千问系列多模态模型，具体使用了三个版本：


模型	用途	特点
qwen3.5-flash	ChineseSimpleVQA公开评测	轻量快速，中英文图文理解
qwen3.5-plus	DuReader_vis文档评测	性能均衡，文档理解能力强
qwen3.6-flash	自建数据集评测	最新版本，推理速度更快

- 辅助技术：
 - 预处理：OpenCV/Pillow（图像尺寸调整、归一化）
 - 评测：Python+JSON批量处理，准确率/匹配度计算
 - 交互：gradio（轻量Web界面）

三、系统设计与实现细节

3.1 系统整体架构

- 输入层：接收图像+文本问题，支持多轮对话上下文
- 预处理层：图像通道转换、尺寸适配；文本对话模板拼接
- 核心推理层：模型加载、跨模态融合、生成回答
- 输出层：回答格式化、对话历史维护
- 评测层：数据集加载、批量推理、指标计算
- 交互层：用户输入/输出展示



系统选用阿里云百炼 DashScope 作为推理后端，通过OpenAI兼容接口调用Qwen3.5-flash / Qwen3.5-plus / Qwen3.6-flash等多模态大模型，避免本地部署的高显存需求和慢推理速度。

3.2 核心模块实现细节

3.2.1 API调用实现

核心代码封装为 VLMQA 类:

```
from openai import OpenAI

class VLMQA:
    def __init__(self, api_key, model_name):
        self.client = OpenAI(
            api_key=api_key,
            base_url="https://dashscope.aliyuncs.com/compatible-mode/v1"
        )
        self.model_name = model_name
```

API调用方式为OpenAI兼容模式，图片通过base64编码后以 data:image/jpeg;base64,xxx

格式嵌入请求体。

3.2.2 图像预处理

图像预处理包含两个关键步骤：

- 本地路径解析：对于URL图片（如ChineseSimpleVQA数据集），先通过 `requests` 下载到本地缓存目录 `data/cache/images/`，使用URL的hash值作为文件名，避免重复下载。
- Base64编码：将本地图片文件读取为二进制，编码为base64字符串，构建符合OpenAI多模态格式的 `image_url` 字段。

```
def _resolve_image_path(self, image_path):
    if image_path.startswith("http://") or image_path.startswith("https://"):
        return self._download_image(image_path)
    return image_path

def _encode_image(self, image_path):
    with open(image_path, "rb") as f:
        return base64.b64encode(f.read()).decode("utf-8")
```

3.2.3 多轮对话输入构建

多轮对话通过维护 `messages` 列表实现。第一轮同时传入图片和问题，后续轮次仅传入文本问题，图片保持在上下文中。

```
def multiround_chat(self, image_path, questions):
    image_base64 = self._encode_image(image_path)
    messages = []
    answers = []

    for i, question in enumerate(questions):
        if i == 0:
            messages.append({
                "role": "user",
                "content": [
                    {"type": "text", "text": question},
                    {"type": "image_url", "image_url": {"url": image_base64}}
                ]
            })
        else:
            messages.append({"role": "user", "content": question})

        answer = self._call_api(messages)
        answers.append(answer)
        messages.append({"role": "assistant", "content": answer})
```

3.2.4 推理Pipeline

API调用参数配置如下：

参数	值	说明
model	qwen3.5-flash/plus/3.6-flash	按数据集分配
temperature	0.1	低温度保证结果稳定可复现
max_tokens	512	限制输出长度，控制Token消耗
max_retries	3	网络异常自动重试

3.2.5 评测模块实现

1. 数据集加载

数据集统一存储为JSON格式，每条样本包含 image（路径）、question、answers（参考答案列表）、question_type。通过 VQADataset 类加载，支持 get_subset(n) 随机抽取子集。

2. 准确率计算

准确率采用三级匹配机制：

- 精确匹配：预测答案与任一参考答案完全一致
- 包含匹配：预测答案包含参考答案，或参考答案包含预测答案
- 关键词匹配：预测答案与参考答案有交集词汇


```
def compute_accuracy(prediction, reference_answers):
    pred = prediction.strip().lower()
    for ref in reference_answers:
        ref = ref.strip().lower()
        if pred == ref:
            return True, "exact_match"
        if ref in pred or pred in ref:
            return True, "contains_match"
        if set(ref.split()) & set(pred.split()):
            return True, "keyword_match"
    return False, "no_match"
```

3.2.6 交互界面实现

- Web界面：基于Gradio框架搭建轻量化交互界面，实现图片上传、文本输入、对话展示一体化可视化布局
- 多轮对话：系统可保存上下文历史记录，支持针对同一张图片进行连续问答与追问

3.3 代码仓库说明

- 项目结构树：



四、实验设计与定量结果

4.1 实验设置

- 实验环境:

单卡RTX 3090/24GB, Python 3.10, transformers 4.45.0

- 评测数据集:

1. ChineseSimpleVQA (100张, 自然场景问答)

• 该数据集为中文自然场景视觉问答数据集, 图片内容以日常生活实景、户外风景、日常物体为主, 提问多为物体识别、场景描述、属性判断等基础视觉问题, 用于测试模型的自然场景视觉理解能力;

2. DuReader_vis (100张, 文档/文字问答)

• 该数据集为百度开源的文档类视觉问答数据集, 图片主要包含试卷、文档截图、打印文字、表格文本等内容, 提问多为文字提取、内容理解、图文匹配任务, 用于测试模型的图文OCR识别与文档理解能力;

3. 自建中文数据集 (15张文档问答, 30张风景问答)

• 本项目手动构建小型测试数据集, 包含文档问答15张、风景场景问答30张。图片来源为真实拍摄与网络公开高清素材, 提问风格更贴近用户自然提问方式, 用于测试系统在真实生活化场景下的泛化能力。

- 评测指标:

- 每条样本有1-3个参考答案
- 采用精确匹配、包含匹配、关键词匹配三级判定
- 采用人工复核, 修正自动匹配的误判

4.2 定量实验结果

数据集类型	样本数量	数据集特点	Qwen3.5-Flash准确率
ChineseSimpleVQA (自然场景)	100	日常物体、户外场景、简单视觉问答	60.00%
DuReader_vis (文档文字)	100	文档截图、印刷文字、表格文本、OCR问答	89.00%
自建数据集-文档类	15	真实拍摄文档、手写文字、模糊文本	100.00%
自建数据集-风景类	30	真实风景、复杂背景、多物体场景	83.33%


数据集类型	样本数量	数据集特点	Qwen3.5-Flash准确率
整体综合平均	245	多场景混合综合测评	77.13%

- **结果分析：**表格为模型在不同类型视觉问答任务中的性能表现，可以看出整体上呈现出文档文字类任务表现优异、自然场景视觉任务表现较薄弱的特征，具体分析如下：

1. 模型在文档文字问答场景适配性极强。模型在自建文档数据集上准确率达到100%，在公开DuReader_vis数据集上准确率高达89.00%，充分说明该轻量化文本大模型具备优秀的文本理解、图文文字匹配与文档内容解析能力，能够精准应对印刷文档、表格文本、实拍文档等各类文字类视觉问答任务，契合其文本模型的能力优势。
2. 自然场景视觉理解为模型核心短板。模型在公开ChineseSimpleVQA自然场景数据集上准确率仅为60.00%，是所有测试场景中准确率最低的场景。核心原因在于Qwen3.5-Flash为纯文本大模型，无原生视觉编码与图像特征提取能力，面对户外风景、多物体叠加、生活化实景等需要视觉感知、细节识别、场景研判的任务时，无法精准捕捉图像视觉信息，仅依靠通用常识推理作答，导致大量识别偏差与回答错误。
3. 真实生活化风景场景泛化能力中等。模型在自建风景数据集上准确率为83.33%，表现优于标准自然场景数据集。原因可能是自建风景图片场景特征清晰、主体明确、干扰信息较少，模型可依托常识知识完成基础场景判断与问答，具备一定的真实场景泛化能力，但仍存在细节识别不精准的问题。
4. 整体综合性能达标。本次245组混合样本测试的整体平均准确率为77.13%，证明本系统整体运行稳定，模型能够适配绝大多数简单文档、清晰风景场景的问答需求，基本实现图文问答的核心功能，但在复杂自然实景的视觉理解任务中存在明显性能瓶颈。

4.3 可视化与错误分析

- 可视化：



- 错误案例分类与分析：

1. 视觉识别错误

- 主要集中在自然、风景数据集，面对遮挡、复杂背景、光线变化、多物体混合场景，模型无法精准提取视觉特征，会出现识别不全、分类错误等问题；

2. OCR/文字识别错误

- 主要集中在DuReader_vis、自建文档数据集，表现为小字识别失败、多行文字乱序、模糊文字无法读取，会导致文字识别错误；

3. 推理逻辑错误

- 模型无法将图像内容与用户问题进行深度关联，只能进行浅层匹配，面对需要结合图像细节推理的问题极易回答错误；

4. 内容幻觉错误

- 当图像信息不足、画面模糊、文字无法识别时，模型会自动编造看似合理但不符合图片真实内容的答案。


- 典型案例展示：（为节省篇幅只有编号1的案例给出例图）

- 成功案例：

1. 问题：“图中右边的人物是在哪一年去世的？”

系统回答：图中右边的人物是法国皇帝拿破仑·波拿巴（Napoleon Bonaparte）。他是在1821年去世的（具体日期为1821年5月5日）。

成功原因：正确识别除了图片中的人物，并且检索出了离世时间。



2. 问题：“图中瀑布上的岩石，其分布与哪类地质活动密切相关？”

系统回答：图中瀑布上的岩石呈现出非常规则的柱状节理（Columnar Jointing）结构，这种独特的岩石分布与火山活动（或岩浆活动）密切相关。

成功原因：能给正确识别图片，并从视觉特征推断地质成因，逻辑完整。

3. 问题：“图片中的动物属于哪个属？”

系统回答：图片中的动物属于狒狒属（学名：Papio）。

成功原因：能够正确识别图片中的动物并给出分类学信息。

4. 问题：“图中的植物在中国最早的文字记载出现于先秦时期的哪一部著作？”

系统回答：图中的植物是萱草（学名：Hemerocallis fulva），在中国古代也被称为谖草或忘忧草。它最早的文字记载出现在先秦时期的著作《诗经》中。

成功原因：正确识别出了图片中的植物，并从植物外观推断品种并追溯文献出处。

- 失败案例：

1. 问题：“图片中的寺庙位于哪个市？”

系统回答：图片中的寺庙位于福建省泉州市。具体来说，这是泉州著名的开元寺（Kaiyuan Temple）内的建筑。

参考答案：新北市。

错误原因：内容幻觉错误，识别出了建筑的基本特征但是由于图中信息不足，自动编造了看似合理但不符合图片真实内容的答案。



2. 问题：“图片中的蘑菇是在什么年份被描述的？”

系统回答：根据图片中蘑菇的特征，这很可能是一种牛肝菌（*Boletus*）。很大概率是由Heinrich Friedrich Link和Johann Christoph Krombholz在1834年描述的（作为*Boletus pinophilus*）。

参考答案：1796年。

错误原因：推理逻辑错误，能识别出是一种牛肝菌，但是没办法与问题进行深度关联，只能进行浅层匹配，导致年份推理错误。

3. 问题：“图片中的蝴蝶属于哪个属？”

系统回答：根据图片中蝴蝶的特征，它属于斑蝶属（*Danaus*）。

参考答案：袖蝶属。

错误原因：视觉识别错误，由于图片光线昏暗，模型无法精准提取视觉特征，出现了分类错误的问题。

4. 问题：“海南白胡椒最新价格”

系统问答：根据您提供的图片，无法提供最新价格，因为图片中的数据已经过时。

参考答案：36.00。

错误原因：OCR/文字识别错误，图片中存在模糊文字无法读取，导致文字识别错误。

五、反思与展望

5.1 项目整体反思

本项目完成了基于大模型的图文问答系统开发，实现了实现“看图能聊天”的多模态交互功能，结合文本问题完成中文问答及基础推理任务等核心功能，基本达成实验预设目标。但在实验过程中，也暴露出模型选型、功能设计、容错能力、场景适配等多方面问题，本节从模型、系统两大维度进行反思总结。

- 现有模型的局限性：

1. 抗干扰能力弱：模型对输入图像质量要求高，光线昏暗、画面模糊、物体遮挡、复杂背景等情况都会直接导致识别失败，无法适配复杂真实场景；
2. 易产生内容幻觉：当图像信息不足或问题超出模型知识范围时，模型容易生成虚假、不实内容，问答可信度下降。

- 系统功能与架构的不足：

1. 前端功能单一：Web界面仅实现基础上传、问答、保存功能，未增加图片裁剪、亮度调节、问答分页、历史记录检索等辅助功能，用户体验有待提升；
2. 异常处理机制不完善：当图像为空、问题为空、网络中断、API调用超时、密钥错误时，系统仅抛出代码报错，缺少友好的前端提示，容错性较差；
3. 对话历史优化不足：多轮对话仅做简单内容拼接，未对历史上下文进行精简、降噪，随着对话轮次增加，冗余信息会影响模型判断。

5.2 AGI视角下的技术瓶颈

从通用人工智能（AGI）发展视角来看，本项目所代表的多模态问答系统，也是当前大模型落地应用的缩影，现存瓶颈具备部分共性：

1. 视觉与语言融合壁垒。当前多数模型仍将视觉解析与语言生成分割处理，难以像人类一样真正做到“看图理解、结合思考”，跨模态信息融合仍是AGI落地的核心难点。
2. 真实世界泛化能力不足。模型依赖训练数据集，对于训练数据之外的小众物体、特殊场景、非常规问题，泛化能力差，无法适应复杂多变的真实生活场景，距离通用感知能力仍有较大差距；
3. 逻辑与因果推理短板。现阶段大模型擅长文本续写与模式匹配，而非真正的逻辑思考，难以建立严谨的因果关系，这也是要实现AGI高阶智能必须突破的问题；
4. 安全性与可靠性问题。内容幻觉、错误输出、隐私泄露等问题普遍存在，在正式落地场景中，输出结果无法做到百分百可信，限制了人工智能的实用价值。

5.3 未来改进方向

1. 模型层面优化。需要再对模型进行微调，针对图文问答场景，使用专项数据集对模型进行轻量化微调，提升模型在本任务下的准确率，减少幻觉与错误输出。还可以组

合调用其他多模型，引入专业OCR模型、图像分类模型与大语言模型协同工作，分工完成视觉解析、文字识别、问答生成，弥补单一模型能力缺陷；

2. 前端交互优化。需要丰富界面功能，例如新增图片预处理工具（裁剪、旋转、亮度调整）、历史对话检索、问答结果导出等功能，提升界面实用性。同时完善异常提示：针对空输入、网络异常、接口报错、密钥失效等场景，设计前端弹窗提示，替代原始代码报错，提升人机交互友好度；

3. 系统架构升级。增加离线部署方案，尝试轻量化多模态模型本地部署，尝试实现离线运行，提升系统稳定性与部署灵活性。优化多轮对话机制，对历史对话进行摘要、降噪处理，剔除冗余信息，保证长轮次对话下模型理解不受干扰；

4. 应用场景拓展。在现有图文问答基础上，拓展应用场景，如试卷识别答疑、商品图文介绍、课堂辅助教学等，让系统从简单实验真正转变为具备实际使用价值的工具。

六、总结

6.1 项目完成情况

本项目完整实现了课程作业要求的全部核心功能，成功搭建了一套基于大模型的多模态图文问答交互系统。系统依托Qwen3.5-Flash模型完成推理接口封装，稳定实现了图像与文本联合问答功能。同时完成多轮上下文对话功能开发，可有效记忆历史对话内容，实现连贯的连续问答交互。在交互层面，基于Gradio搭建轻量化Web可视化界面，实现图片上传、文本提问、对话展示、记录保存等可视化操作。实验层面，选用ChineseSimpleVQA、DuReader_vis两类公开数据集及自建混合数据集完成多场景测试，通过准确率量化计算、数据可视化、典型成功与失败案例剖析，完成全方位系统评测，完整落地课程要求的所有开发与实验任务，系统功能完整、实验数据详实、结果分析规范。

6.2 收获与体会

通过本次多模态图文问答系统的开发实践，让我们系统掌握了大模型接口配置、模型推理封装、前后端交互开发的完整流程，深入理解了多模态问答任务的核心逻辑与技术架构。在模型适配过程中，明晰了纯文本大模型与专业视觉多模态模型的能力差异，深刻认知了多模态融合、视觉特征提取、图文联合推理等技术难点。同时，完整参与了系统模块化设计、多数据集实验评测、数据可视化分析、案例归纳总结及标准化报告撰写的全流程工作，不仅提升了Python开发、模型调用、系统调试的实操能力，也培养了工程化思维、问题排查能力与实验分析能力。本次项目实践让我们对人工智能多模态技术的落地应用有了更直观、深刻的认知，为后续相关技术的学习与项目开发积累了扎实的实践经验。

参考文献:

- [1] Bai J, Bai S, Yang S, 等. Qwen-VL: A Versatile Vision-Language Model[EB/OL]. 2023.
- [2] 包希港, 周春来, 肖克晶, 等. 视觉问答研究综述[J]. 软件学报, 2021, 32(8): 2522-2544.
- [3] Gu J H, Wang Y Y, Bu P, 等. ChineseSimpleVQA: See the World, Discover Knowledge: A Chinese Factuality Evaluation for Large Vision Language Models[J/OL]. arXiv, 2025:2502.11718.
- [4] Qi L, Lv S W, Li H Y, 等. DuReader_vis: A Chinese Dataset for Open-domain Document Visual Question Answering[C]//Findings of the Association for Computational Linguistics: ACL 2022. Dublin, Ireland: Association for Computational Linguistics, 2022:1338-1351.